阳光保险 H20-141G-DeepSeek-R1-0528 POC 测试报告

1. 测试目的

在阳光保险提供的H20（141G）上，基于趋境科技的方案对DeepSeek-R1-0528开展POC测试。

2. 基本信息

项目	内容
项目	基于8卡H20（141GiB）的DeepSeek-R1-0528 POC测试
模型	DeepSeek-R1-0528
时间	2026年4月3日

3. 测试环境

3.1 硬件配置

硬件	配置信息
CPU	Intel(R) Xeon(R) 6759P-C（240 Core）
GPU	NVIDIA H20-3e(141GiB) * 8
内存	1.9Ti

3.2 软件配置

软件名称	版本信息
操作系统	Ubuntu
CUDA版本	12.8
测试工具	evalscope v1.4.2

4. 测试用例

4.1 推理加速-PD分离性能

项目	内容
描述	厂商需在我单位2台H20组成的集群环境中，基于自研推理引擎实现DeepSeek-R1-671B-FP8模型PD分离深度推理优化，要求Token吞吐量相比2个独立H20模型实例之和提升1倍以上，并交付推理引擎组件与性能对比测试报告。
执行测试	python3 run_perf_test.py --port 35000 --model DeepSeek-R1-0528 --tokenizer-path /mnt/raid/models/DeepSeek-R1-0528/ --input-length 1024 --output-length 1024 --parallel "1024" --number "1024"
数据	- 单机数据 - 1P1D数据

```
{
    "Time taken for tests (s)": 1190.6311,
    "Number of concurrency": 1024,
    "Request rate (req/s)": -1.0,
    "Total requests": 2048,
    "Succeed requests": 2048,
    "Failed requests": 0,
    "Output token throughput (tok/s)": 1761.3784,
    "Total token throughput (tok/s)": 3524.477,
    "Request throughput (req/s)": 1.7201,
    "Average latency (s)": 479.5436,
    "Average time to first token (s)": 321.9586,
    "Average time per output token (s)": 0.154,
    "Average inter-token latency (s)": 0.154,
    "Average input tokens per request": 1025.0,
    "Average output tokens per request": 1024.0
}
```

```
{
    "Time taken for tests (s)": 271.4781,
    "Number of concurrency": 1024,
    "Request rate (req/s)": -1.0,
    "Total requests": 2048,
    "Succeed requests": 2048,
    "Failed requests": 0,
    "Output token throughput (tok/s)": 7724.9394,
    "Total token throughput (tok/s)": 15457.4226,
    "Request throughput (req/s)": 7.5439,
    "Average latency (s)": 116.4555,
    "Average time to first token (s)": 36.9586,
    "Average time per output token (s)": 0.0777,
    "Average inter-token latency (s)": 0.2595,
    "Average input tokens per request": 1025.0,
    "Average output tokens per request": 1024.0
}
```

是否通过	是

4.2 推理加速-单机推理性能

项目	内容
描述	厂商需在我单位单台H20上，基于自研推理引擎实现DeepSeek-R1-671B-FP8模型深度推理优化，在输入1K，输出1K的场景，Token输出速度超过3000token/s，并交付性能测试报告。
执行测试	python3 run_perf_test.py --port 35000 --model DeepSeek-R1-0528 --tokenizer-path /mnt/raid/models/DeepSeek-R1-0528/ --input-length 1024 --output-length 1000 --parallel "200" --number "200"

```
{
    "Time taken for tests (s)": 56.7232,
    "Number of concurrency": 200,
    "Request rate (req/s)": -1,
    "Total requests": 200,
    "Succeed requests": 200,
    "Failed requests": 0,
    "Output token throughput (tok/s)": 3313.6517,
    "Total token throughput (tok/s)": 6927.6918,
    "Request throughput (req/s)": 3.5259,
    "Average latency (s)": 44.2937,
    "Average time to first token (s)": 9.7426,
    "Average time per output token (s)": 0.1194,
    "Average inter-token latency (s)": 0.1293,
    "Average input tokens per request": 1025.0,
    "Average output tokens per request": 939.805
}
```


是否通过	是

4.3 算力拆分

项目	内容
描述	支持在单张物理GPU硬件资源上同时承载多个独立的大模型推理实例，需具备精细化显存资源调度能力，可通过动态显存分配、模型权重共享等技术，实现对GPU显存、计算单元等硬件资源的逻辑隔离与弹性分配，避免多实例间资源抢占冲突，保障多实例并发部署时的推理性能稳定性，并交付测试报告。
执行测试	基于AMaaS平台手动选卡，内部会根据模型配置和启动参数拆分算力，且实例间互不影响。

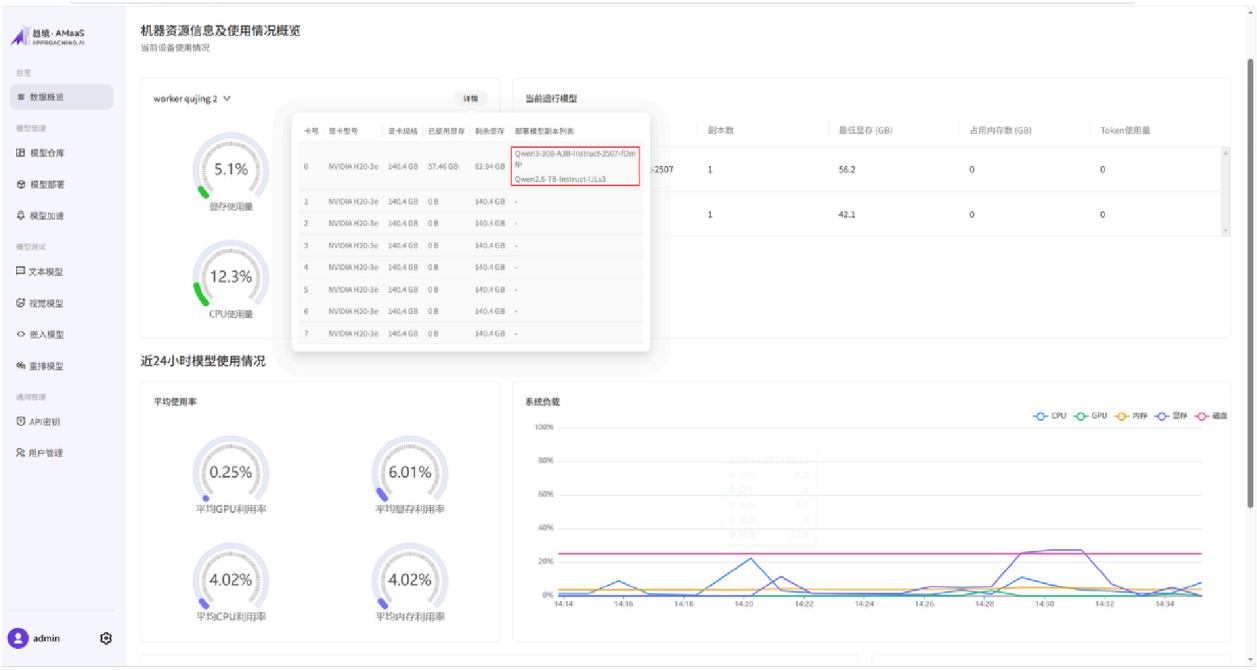
机器资源信息及使用情况概览
当前设备使用情况
worker qujing 2
5.1%
显存使用量
12.3%
CPU使用量
当前运行模型
近24小时模型使用情况
平均使用率
0.25%
平均GPU利用率
6.01%
平均显存利用率
4.02%
平均CPU利用率
4.02%
平均内存利用率
系统负载
admin

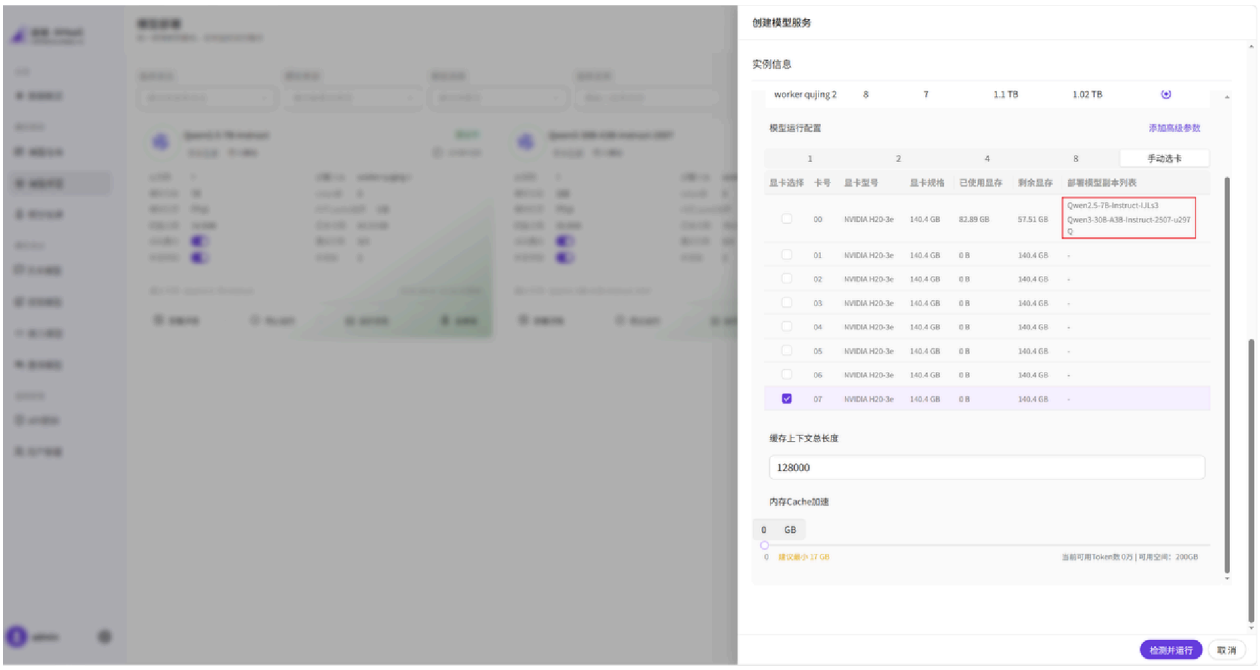
创建模型服务
实例信息
worker qujing 2
模型运行配置
添加高级参数
手动选卡
缓存上下文总长度
128000
内存Cache加速
检测并运行
取消

是否通过	是

4.4 算力超分

项目	内容
描述	支持DeepSeek-R1-671B-FP8精度模型在单机单卡H20硬件环境部署，Prefill速度达到300token/s，Decode速度达到15token/s，并交付测试报告。
执行测试	python3 run_perf_test.py --port 35000 --model DeepSeek-R1-0528 --tokenizer-path /mnt/raid/models/DeepSeek-R1-0528/ --input-length 512 --output-length 10 --parallel "1" --number "1"


```
{
    "Time taken for tests (s)": 15.4124,
    "Number of concurrency": 1,
    "Request rate (req/s)": -1,
    "Total requests": 10,
    "Succeed requests": 10,
    "Failed requests": 0,
    "Output token throughput (tok/s)": 6.4883,
    "Total token throughput (tok/s)": 339.3361,
    "Request throughput (req/s)": 0.6488,
    "Average latency (s)": 1.5407,
    "Average time to first token (s)": 0.9293,
    "Average time per output token (s)": 0.0679,
    "Average inter-token latency (s)": 0.0679,
    "Average input tokens per request": 513.0,
    "Average output tokens per request": 10.0
}
```


是否通过	是

4.5 多轮对话场景

项目	内容
描述	模拟真实高并发客服业务场景，验证推理引擎在多用户同时进行多轮对话时的性能表现。重点测试系统对历史对话记录的KV Cache缓存与复用能力。通过在多轮交互中减少重复计算，验证其能否有效降低首字延迟（TTFT）并提升并发承载能力，确保在长上下文链路下用户仍能获得极速的响应体验，并交付多用户场景下的性能测试报告。
执行测试	python3 bench_multiturn.py --model-path /mnt/data/models/DeepSeek-R1-0528 --port 35000 --disable-random-sample --output-length 1 --request-length 3000 --num-clients 40 --num-rounds 10 --max-parallel 4 --request-rate 16 --ready-queue-policy random --disable-auto-run --enable-round-barrier --dataset-path /mnt/data/models/perftest/sharegtp_dataset/ShareGPT_V3_unfiltered_cleaned_split.json

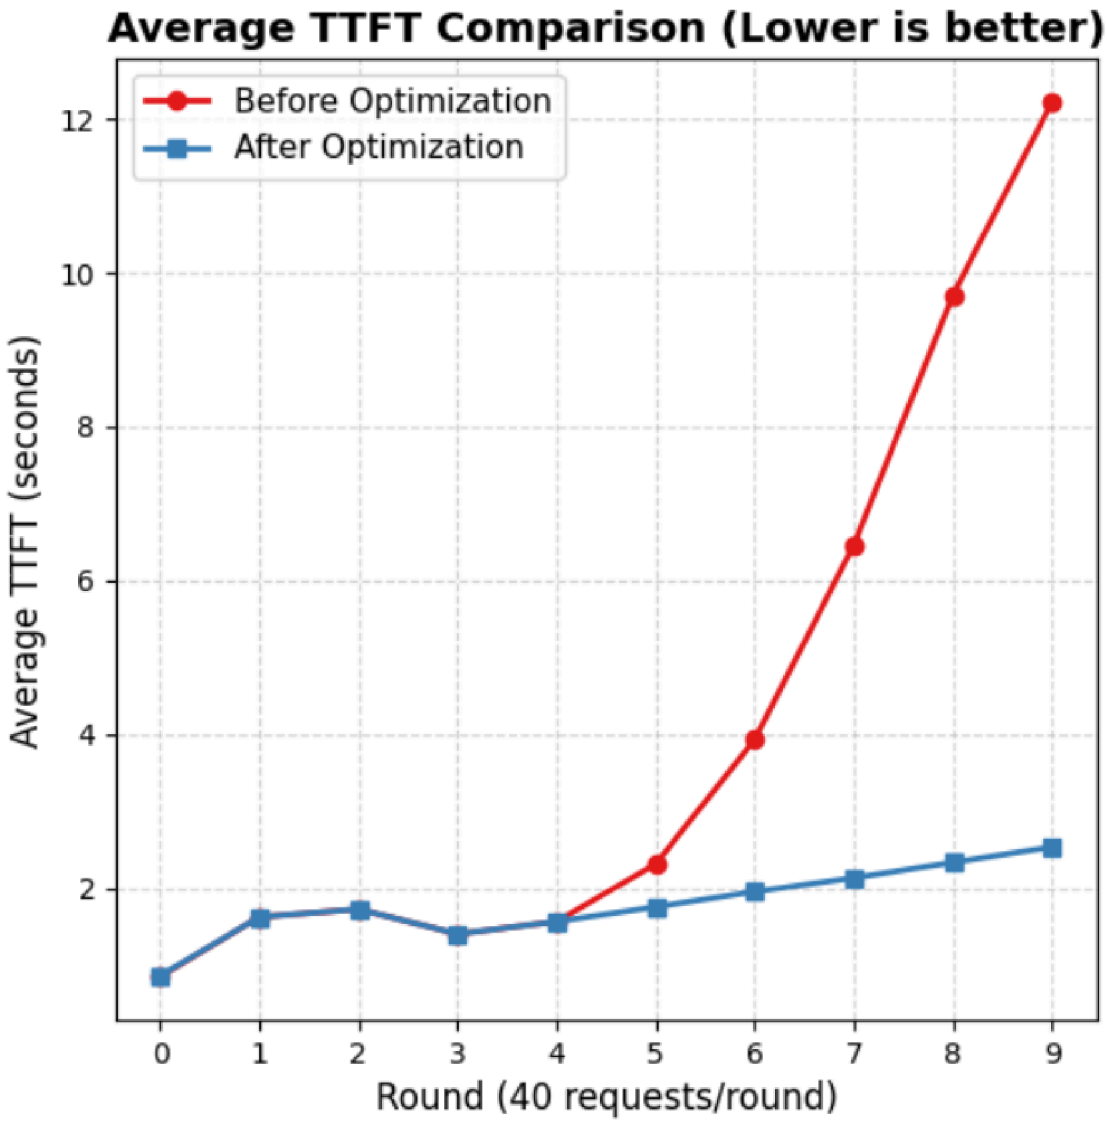

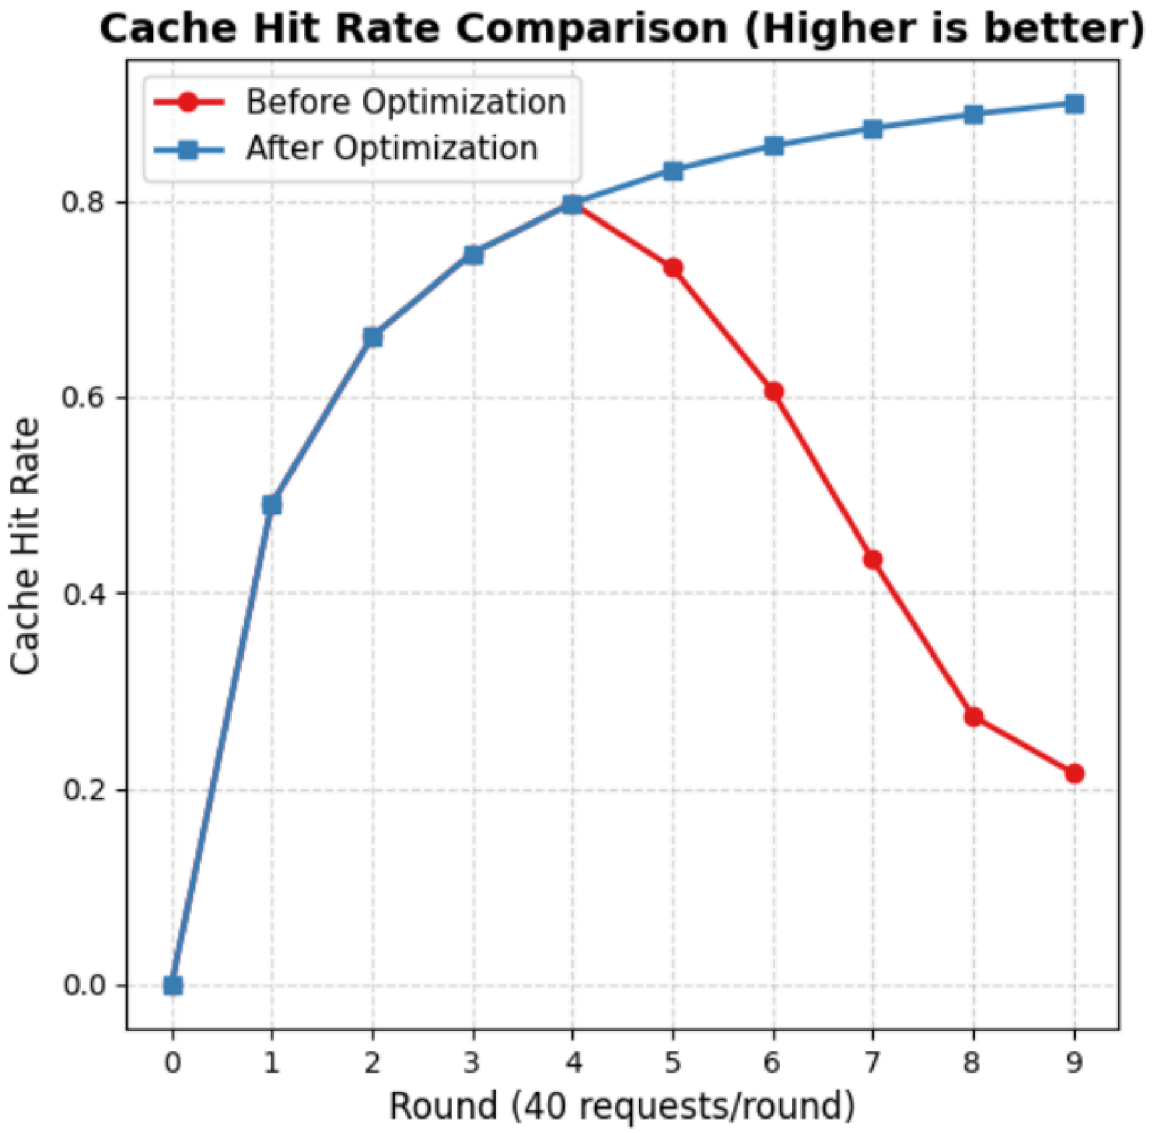

是否通过	是

5. 测试结论

- pd分离性能Token吞吐量能达到2个独立H20模型实例之和的1倍以上 ✅
- 输入1k输出1k的场景，Token输出速度可以超过3000token/s ✅
- 支持单张物理GPU的算力拆分，在单张物理GPU硬件资源上同时承载多个独立的大模型推理实例 ✅
- 单卡kt异构prefill速度可以达到300token/s，Decode速度达到14.73token/s ✅
- 高并发多轮对话测试中，开启优化方案后，首字延迟（TTFT）随轮次增长保持极高稳定性。在第10轮交互时，TTFT仅为2.53s，相比未开启状态（12.22s）降低了4.8倍，且缓存命中率

稳定在90%左右。✅

6. 附件

- 详细的硬件信息
- 单机常规性能基线数据
- 1P1D常规性能数据